



Triển Khai Thực Tế, Chi Phí Vận Hành & Định Hướng Chuyên Sâu

AICB-P1 · Ngày 15 · Ngày cuối Phase 1

Tên Giảng Viên

VinUniversity · Phase 1 · 2026

HÃY SUY NGHĨ...

“15 ngày trước bạn chưa biết LLM hoạt động thế nào. Hôm nay bạn đã có agent deployed, monitored, và evaluated. Câu hỏi bây giờ: đi sâu hướng nào?”

Giữ câu hỏi này trong đầu khi học bài hôm nay


1. 15 ngày nhìn lại
2. Triển khai enterprise
3. Cost anatomy
4. Cost optimization
5. Scaling production
6. Skills map recap
7. 3 Track Phase 2
8. Career paths & AMA

- Hiểu **thách thức triển khai enterprise**: security, compliance, legacy systems
- Phân tích **cost anatomy** của AI system và biết cách tối ưu chi phí
- Nắm **cost optimization strategies**: model routing, semantic caching, prompt compression
- Nhìn lại **skills map** đã tích lũy qua 15 ngày
- Chọn **track Phase 2** phù hợp với mục tiêu nghề nghiệp

15 Ngày Nhìn Lại

Từ “AI là gì?” đến agent deployed, monitored, evaluated –
một hành trình 15 ngày xây dựng năng lực thực chiến

01



3 giai đoạn: **Hiểu nền tảng** (N1-5) → **Xây dựng hệ thống** (N6-10) → **Đưa lên production** (N11-15)

- Gọi LLM API, so sánh models
- Build ReAct agent + tool calling
- RAG pipeline grounded
- Multi-agent + MCP
- Guardrails + safety testing

- Problem statement + PRD
- UX với trust layer
- Deployed trên cloud
- Monitoring + alerting
- Evaluation + benchmark

Bạn không chỉ học lý thuyết. Bạn đã **build, deploy, monitor, và evaluate** một AI product thật.

Triển Khai Enterprise

Lab deploy lên Railway là bước đầu. Enterprise có thêm security policies, compliance, legacy systems, và network restrictions

02

Security & Compliance

- Data không được rời khỏi VN
- PII phải encrypted at rest
- Audit trail cho mọi AI decision
- Compliance: PDPA, ngành tài chính

Technical Constraints

- Legacy systems, mainframe
- Network restrictions, air-gapped
- On-premise infrastructure only
- Limited GPU resources

Lưu ý: Enterprise deploy khác startup deploy. Không phải mọi thứ đều “push lên cloud” được. Đôi khi LLM phải chạy **on-premise**.

	Cloud API	On-Premise	Hybrid
Data control	Thấp	Cao nhất	Tùy chọn
Setup time	Phút	Tuần-tháng	Tuần
Cost model	Per-token	Capex + GPU	Mixed
Performance	Nhanh	Tùy hardware	Tùy routing
Best for	MVP, startup	Bank, gov	Enterprise

Hybrid đang trở thành default cho enterprise VN: **sensitive data on-prem**, non-sensitive qua cloud API.

Production-grade inference.

PagedAttention, continuous batching.

Dùng khi: cần throughput cao, có GPU server

Run models locally, dễ setup.


Download model, chạy 1 lệnh.

Dùng khi: dev, demo, edge deployment

Lưu ý: Self-hosted tiết kiệm khi volume cao (> 1M tokens/ngày). Dưới mức đó, **cloud API rẻ hơn** khi tính cả chi phí GPU, ops, và maintenance.

Cost Anatomy Của AI System

AI agent production không chỉ tốn tiền token. Hiểu đầy đủ cost structure mới optimize đúng chỗ



API tokens chiếm 40-60% cost. Optimize token usage là **ROI cao nhất** cho hầu hết AI systems.

Monthly cost =

(avg input tokens + avg output tokens)

× price per token

× requests per day

× 30 ngày

1000 tokens/request

\$3/1M input tokens (Sonnet)

500 requests/ngày

= $1000 \times \$0.000003 \times 500 \times 30$

= **\$45/tháng** chỉ LLM API

Lưu ý: Hidden costs thường gấp 1.5–2x API cost: retry overhead, guardrails LLM calls, monitoring, eval pipeline. Budget phải tính **tổng**, không chỉ API.

Tier	Traffic		Estimated cost	Stack
MVP	< 100 q/ngày	re-	\$50– 200/tháng	Cloud API + Rail- way
Growth	100–5K q/ngày	re-	\$200– 2K/tháng	Cloud API + EC- S/Cloud Run
Scale	> 5K req/ngày		\$2K+/tháng	Hybrid / self- hosted

Bắt đầu MVP tier. Chỉ upgrade khi traffic thật sự đòi hỏi. **Premature optimization is the root of all evil.**

Cost Optimization Strategies

Khi cost bắt đầu đáng kể, 4 strategies sau giúp giảm 30–70% chi phí mà không ảnh hưởng chất lượng

Cheap model (Haiku) cho simple tasks.

Expensive model (Opus) chỉ cho complex.

Tiết kiệm: 40–60% token cost

Cache LLM responses cho similar queries.

Dùng embedding similarity để match.


Tiết kiệm: 20–40% nếu queries lặp

Tóm tắt context trước khi gửi LLM.
Giảm token count mà giữ thông tin.

Tiết kiệm: 15–30% input tokens

vLLM, Ollama cho high-volume.
Break-even: khoảng 1M+ tokens/ngày.

Tiết kiệm: 50–80% so với API khi scale



Nếu 70% requests dùng cheap model (10x rẻ hơn), tổng cost giảm khoảng **50%** mà quality gần như không đổi trên simple tasks.

Scaling & Reliability Production

Khi agent phục vụ enterprise, cần thêm queue, circuit breaker, và SLA commitment

High load → request queue → smooth out spikes.

User nhận “đang xử lý” thay vì timeout.

Tool: Redis Queue, Celery, Bull

Khi LLM API down, degrade gracefully.

Trả cached response hoặc fallback message.

Pattern: closed → open → half-open

Stateless agent → N instances.

Day 12: đã design cho stateless.

Scale: thêm instances khi load tăng

Enterprise cần uptime commitment.

99.9% = max 8.7h downtime/năm.

Cần: redundancy, failover, monitoring

Skills Map Sau 15 Ngày

3 competency pillars đã được xây dựng – mỗi pillar mở ra một career direction khác nhau

CP3: AI Engineering

- LLM API
- ReAct Agent
- Prompt Engineering
- Tool Calling
- Embedding
- RAG Pipeline
- Multi-Agent
- Guardrails
- Evaluation

CP2: Infrastructure

- Vector Store
- Data Pipeline
- Docker
- Cloud Deploy
- Monitoring
- Structured Logging
- Tracing

CP1: Business

- Problem Statement
- AI Readiness
- PRD
- Risk Assessment
- ROI Analysis
- UX Design
- Cost Analysis

Sau 15 ngày: bạn đã có **deployed, monitored, evaluated AI product** + skills across 3 pillars.

3 Track Giai Đoạn 2

Phase 1 cho nền tảng chung. Phase 2 đi sâu theo hướng bạn chọn – mỗi track 3 tuần chuyên sâu



Nội dung chính

- Product Strategy cho AI products
- Financial Modeling & ROI
- AI Governance & Compliance
- AI Act & regulatory landscape
- Go-to-market cho AI products

Người muốn làm:
AI Product Manager
AI Business Analyst
AI Strategist

Business plan cho AI product + financial model + compliance checklist + go-to-market strategy.

Nội dung chính

- Lakehouse & Feature Store
- vLLM deployment & optimization
- CI/CD cho AI (LLMOps)
- GPU FinOps & cost management
- Production data pipeline

Người muốn làm:
AI Data Engineer
Platform Engineer
MLOps Engineer


Production-grade data pipeline + self-hosted LLM + CI/CD pipeline + monitoring dashboard.

Nội dung chính

- Advanced Agent patterns
- Memory & long-term context
- GraphRAG & knowledge graphs
- Fine-tuning & model customization
- Production evaluation systems

Người muốn làm:
AI Engineer
LLM Engineer
AI Agent Developer

Advanced agent system + custom fine-tuned model + production eval pipeline + technical portfolio.



Lưu ý: Không có track “đúng” hay “sai”. Chọn theo **mục tiêu nghề nghiệp** và **hứng thú cá nhân**. Có thể đổi track sau tuần đầu nếu cần.

Career Paths & Kết Thúc Phase 1

15 ngày, 15 labs, 1 deployed product. Bạn không còn là beginner – bạn là builder

Pillar	Roles	Track	Demand
CP1	AI PM, AI BA, AI Strategist	Track 1	Cao, khan hiếm
CP2	AI Data Engineer, Platform Eng, MLOps	Track 2	Rất cao
CP3	AI Engineer, LLM Engineer, Agent Dev	Track 3	Cao nhất

Từ portfolio khóa học → dự án thực tế tại Vingroup. **Portfolio mạnh = cánh cửa mở.**

Mọi câu hỏi về kỹ thuật, career, track selection, hoặc bất kỳ điều gì bạn muốn hỏi.

Câu hỏi hay gặp nhất:

- “Track nào dễ xin việc hơn?” – *Cả 3 đều thiếu người. Chọn theo thể mạnh.*
- “Fine-tuning có cần không?” – *80% use cases không cần. RAG + prompt đủ.*
- “AI sẽ thay lập trình viên không?” – *AI thay code, không thay builder.*

1. Hoàn thành track selection form
2. Submit portfolio link (GitHub/demo URL)
3. Cost analysis cho agent (Lab 15)
4. Final presentation (10 phút)

- Deployed agent URL
- Monitoring dashboard screenshot
- Evaluation report + RAGAS scores
- README giải thích architecture
- Cost analysis

Những ý chính cần nhớ trước khi sang bài tiếp theo

- 1 **Enterprise deploy** khác startup: security, compliance, on-premise, hybrid. Hiểu context trước khi chọn architecture.
- 2 **Cost optimization:** model routing, semantic caching, prompt compression. API tokens chiếm 40–60% cost – optimize đúng chỗ.
- 3 **3 pillars, 3 tracks:** CP1 (Business) → Track 1, CP2 (Infra) → Track 2, CP3 (Application) → Track 3. Chọn theo mục tiêu.
- 4 **You are no longer beginners – you are builders.** 15 ngày, 15 labs, 1 deployed product. Phase 2 đi sâu hơn.

1. Anthropic & OpenAI Pricing Docs – anthropic.com/pricing, platform.openai.com/tokenizer. Cost calculator.
2. vLLM Documentation – docs.vllm.ai. Self-hosted LLM inference, PagedAttention, quantization.
3. Strubell et al. (2019), *Energy and Policy Considerations for Deep Learning in NLP* – [arXiv:1906.02243](https://arxiv.org/abs/1906.02243).

Hỏi & Đáp

15 ngày từ zero đến deployed AI product. Phase 2 bắt đầu hành trình chuyên sâu của bạn.



Cảm ơn!

Tên Giảng Viên

Email: a.nguyen@vinuni.edu.vn

Tài liệu: github.com/vinuni/aicb-materials

Chúc mừng hoàn thành Phase 1!